

FORD VISION

PROJETO DE SEGMENTAÇÃO E SCORING PREDITIVO PARA RETENÇÃO NO PÓS-VENDA

Disciplina: Inteligência Artificial & Machine Learning

Instituição: FIAP — Faculdade de Informática e Administração Paulista

Parceiro Corporativo: Ford Motor Company

Turma: 3ESS — Engenharia de Software

Sprint: Sprint 3 — 2º Semestre / 2026

Integrantes do Grupo de Desenvolvimento:

Ricardo Di Tilia (RM555155) | Bento Rangel (RM559124) | Eric Yuji (RM554869) | Kauê Pires
(RM554403) | Higor Batista (RM558907)

Este relatório atualiza e substitui a versão da Sprint 1, incorporando comparação de algoritmos, ajuste de hiperparâmetros, análise de sensibilidade das features e deploy do modelo em API.

1. INTRODUÇÃO E CONTEXTUALIZAÇÃO DO PROBLEMA DE NEGÓCIO

A sustentabilidade financeira e a rentabilidade de longo prazo de uma montadora automobilística dependem fortemente da eficiência de sua rede de pós-venda. No cenário da América do Sul, a Ford Motor Company identificou a necessidade crítica de impulsionar o seu indicador de VIN Share, que mensura a fatia de veículos ativos da marca que realizam manutenções, reparos e revisões periódicas dentro das concessionárias autorizadas, em detrimento de oficinas mecânicas independentes. A perda do vínculo com o cliente após o término do período de garantia de fábrica representa uma degradação significativa no Customer Lifetime Value (LTV) e reduz a previsibilidade de receita operacional da rede concessionária.

O principal obstáculo para a mitigação desse cenário reside no caráter reativo das abordagens tradicionais de Relacionamento com o Cliente (CRM). Sistemas convencionais operam identificando a evasão apenas após um longo período de inatividade do veículo, momento em que o resgate do consumidor exige custos promocionais elevados e possui baixa taxa de conversão.

Para mitigar esse gap operacional, o projeto Ford Vision propõe uma solução fundamentada em Ciência de Dados, dividida em duas grandes fases metodológicas. Primeiramente, aplica-se uma modelagem não supervisionada sobre a base histórica de serviços para o mapeamento e a caracterização de perfis comportamentais distintos. Em seguida, implementa-se um pipeline de aprendizado supervisionado baseado em variáveis cadastrais do veículo — modelo, ano, e prazos de venda, entrega e garantia — para classificar o perfil provável de qualquer veículo da **base ativa**, sem depender do histórico de visitas. Essa classificação viabiliza a ativação de réguas de relacionamento segmentadas e a geração de leads de retenção priorizados por concessionária.

Nota de enquadramento desta Sprint. A versão anterior do projeto (Sprint 1) descrevia o modelo como uma predição no "Dia Zero" da venda. A investigação aprofundada realizada nesta Sprint (seção 6.4) mostra que grande parte do poder preditivo do modelo vem do tempo decorrido desde o início da garantia — uma informação que só existe depois que o veículo já está em uso, não no instante da venda. Por essa razão, o projeto foi reenquadrado como um **scoring da base ativa de veículos**: uma ferramenta para priorizar ações de retenção sobre a carteira já vendida, e não uma previsão feita no momento do faturamento. Essa mudança de enquadramento é tratada com transparência ao longo deste relatório, pois consideramos que é parte do rigor técnico exigido pelo desafio.

2. ANÁLISE EXPLORATÓRIA, TRATAMENTO DE DADOS E GOVERNANÇA DO PIPELINE

O volume de dados disponibilizado para o estudo compreende uma matriz transacional com 602.788 registros de passagens pelas oficinas da rede oficial Ford no Brasil, cobrindo o período de janeiro de 2020 a maio de 2026, distribuídos em 20 modelos de veículos e 175.554 VINs únicos. Para garantir a integridade estatística das modelagens subsequentes, o ecossistema passou por um processo de auditoria e saneamento em duas frentes.

Na análise da distribuição das quilometragens reportadas, foram detectados 2.582 registros (0,43% da base) com valores superiores a 1.000.000 km rodados — falhas de preenchimento que distorceriam os centroides dos algoritmos de agrupamento — e esses registros foram removidos. Adicionalmente, ao inspecionar a distribuição da variável de número de revisão (MaintenanceNumber), identificou-se uma concentração anômala e isolada de 1.422 registros (0,24% da base, em 1.270 VINs) com o

código 99 (ou 100) — um valor incompatível com a progressão natural de 1ª, 2ª, 3ª revisão observada no restante da base, e tratado como código sentinela/inválido. Esse número foi invalidado antes do cálculo de métricas como o número máximo de revisão, evitando que um artefato de sistema fosse interpretado como comportamento real de cliente.

Superada a fase de limpeza, a base transacional (600.206 registros) sofreu um processo de agregação estrutural tendo como chave primária o Número de Identificação do Veículo (VIN), mudando o nível de granularidade de "passagens por ordem de serviço" para "veículos únicos" — consolidando um volume final de **175.137 instâncias**. A partir dessa agregação, foram engenheiradas oito métricas comportamentais: volumetria total de visitas, máxima revisão atingida, quilometragem percorrida entre visitas, intervalo de dias entre a primeira e a última visita, recência (dias desde a última interação), número de concessionárias distintas visitadas, status de vigência da garantia e idade do veículo. Valores residualmente extremos em quilometragem percorrida e total de visitas foram winsorizados no percentil 99,9 (176 e 165 veículos ajustados, respectivamente) antes da padronização estatística.

3. MODELAGEM NÃO SUPERVISIONADA: SEGMENTAÇÃO ALGORÍTMICA COM K-MEANS

A estruturação dos perfis de pós-venda foi executada por meio do algoritmo K-Means sobre as oito features comportamentais padronizadas. Devido à complexidade computacional quadrática do cálculo do coeficiente de silhueta, adotou-se a prática usual em Data Science de extrair uma amostra aleatória de 10.000 registros (5,7% da base) para guiar a escolha do número de agrupamentos (K), testando de K=2 a K=8 e cruzando o Método do Cotovelo, o Silhouette Score e o índice Davies-Bouldin.




Figura 1 — Inércia, Silhouette Score e Davies-Bouldin para K de 2 a 8 (amostra de 10.000 registros).

A avaliação por amostragem indicou K=3 como o valor de melhor silhueta (0,4535), com K=4 ligeiramente inferior (0,4347). Para validar essa escolha com rigor, a comparação entre K=3 e K=4 foi refeita sobre a base completa e tratada (175.137 registros), confirmando a vantagem do K=3 (silhouette 0,453 e Davies-Bouldin 1,011, contra 0,440 e 1,143 do K=4).

Nota de correção metodológica. Na Sprint 1, o K=4 havia sido descartado sob a justificativa de produzir "um cluster espúrio de apenas 3 registros com quilometragem extrema". Ao reproduzir a análise nesta Sprint com o código de revisão sentinela devidamente tratado (seção 2), essa explicação não se confirmou: o K=4 gera quatro grupos de tamanho substancial (entre 12.237 e 70.418 veículos), sem clusters degenerados. Ele simplesmente subdivide o grupo de clientes fiéis em dois perfis mais

finos — um de fidelidade intensiva e outro em declínio — o que é uma leitura de negócio válida, porém com separação estatística inferior à do $K=3$. A escolha de $K=3$ nesta Sprint permanece a mesma da Sprint 1, mas agora apoiada em uma comparação correta e reproduzível, documentada como trabalho futuro no encerramento deste relatório.

4. CARACTERIZAÇÃO DOS PERFIS ESTRATÉGICOS E SENSIBILIDADE COMERCIAL

Os três agrupamentos resultantes foram interpretados a partir de seus centroides e correlacionados com as dores comerciais da Ford, revelando uma base polarizada em que os perfis de risco (Esquecido e Abandono) somam **79,6%** do volume de clientes monitorados.

Perfil	Volume / Proporção	Comportamento Observado	Régua de Relacionamento
Cliente Esquecido	70.097 clientes (40,0%)	Garantia de fábrica ativa e contato recente com a rede, mas histórico irregular de revisões. Risco de evasão potencial, ainda não concretizado.	Alertas automáticos por app/WhatsApp, ênfase na blindagem da garantia e agendamento preventivo com um clique.
Cliente de Abandono	69.253 clientes (39,5%)	Ciclos defasados, recência elevada (mediana acima de 1.300 dias) e garantia já expirada. Núcleo mais crítico de perda de VIN Share.	Campanhas de reativação via CRM, vouchers de diagnóstico e desconto progressivo na próxima revisão.
Cliente Fiel	35.787 clientes (20,4%)	Engajamento histórico de alta intensidade (média de 7,8 visitas), fidelidade consolidada à rede oficial.	Programa de fidelidade, prioridade de agenda e cross-selling de acessórios originais.

Comparado à Sprint 1 (78,7% em risco, com 70.829 "Esquecidos", 66.941 "Abandonos" e 37.367 "Fiéis"), o reprocessamento desta Sprint — com o tratamento do código de revisão sentinela e a winsorização de outliers — produziu uma distribuição próxima, com uma leve redução do grupo Fiel em favor do grupo Abandono. As conclusões de negócio da Sprint 1 permanecem válidas.

5. MODELAGEM SUPERVISIONADA: DEFINIÇÃO DO PROBLEMA E POLÍTICA DE FEATURES

Com os perfis consolidados pela análise não supervisionada, o projeto avançou para a construção do motor preditivo (Base 2): um classificador multiclasse que recebe atributos cadastrais do veículo e estima seu perfil de pós-venda provável, sem depender do histórico de visitas.

O edital do desafio estabelece a proibição de vazamento de dados (data leakage) — o uso, no treino, de variáveis que só existem depois do momento em que a predição seria feita. A Sprint 1 declarava conformidade total com essa exigência sob a hipótese de predição no "Dia Zero". Esta Sprint foi além da declaração e **testou** essa hipótese diretamente (seção 6.4), encontrando uma forma de circularidade parcial: o rótulo de cada veículo foi construído, na etapa não supervisionada, a partir de variáveis como o status de vigência da garantia — que é função da mesma data usada para calcular a feature `tempo_garantia_ate_hoje`. Diante disso, a política de features foi revista para privilegiar honestidade sobre o desempenho reportado:

Feature	Situação	Justificativa
ano_modelo	Mantida	Atributo cadastral do veículo.
ModelName (one-hot)	Mantida	Linha do veículo (Ranger, Territory, Maverick...).
dias_venda_entrega	Mantida	Prazo logístico da venda (cadastro).
dias_entrega_garantia	Mantida	Prazo até ativação da garantia (cadastro).
tempo_garantia_ate_hoje	Mantida, com ressalva	Tempo decorrido desde o início da garantia até a data de pontuação. Existe apenas após a venda — é a base do reenquadramento como "scoring da base ativa" (seção 1).
idade_veiculo_proxy	Removida	Redundante com ano_modelo.
MainSource, IsAgendaSchedule	Removida	Provenientes da primeira visita de serviço (pós-venda); indisponíveis para um veículo sem visitas.
KM, MaintenanceNumber e demais features de visita	Removida	Definem o próprio rótulo (seção 3).

6. AVALIAÇÃO DE DESEMPENHO E CRITÉRIOS TÉCNICOS DE SELEÇÃO DE ARQUITETURAS

6.1 Baselines de referência

Antes de comparar algoritmos, três referências simples foram medidas no conjunto de teste (35.028 veículos, 20% da base, nunca usados em treino ou ajuste): a previsão da classe majoritária, e duas árvores rasas treinadas com uma única feature cada. Esse passo, ausente na Sprint 1, é o que permite avaliar se um modelo complexo está realmente agregando valor.

Referência	Acurácia	F1 macro	ROC-AUC
Classe majoritária	0,400	0,191	0,500
Só ano_modelo (árvore rasa)	0,791	0,736	0,886
Só tempo_garantia_ate_hoje (árvore rasa)	0,818	0,745	0,896

6.2 Comparação de algoritmos

A Sprint 1 comparou três famílias de algoritmos. Nesta Sprint, a comparação foi ampliada para cinco famílias — Regressão Logística, Árvore de Decisão, Random Forest, Gradient Boosting (HistGradientBoostingClassifier) e uma rede neural do tipo MLP — todas avaliadas com o mesmo pré-processamento (imputação e padronização/one-hot dentro de um Pipeline, sem vazamento estatístico) e a mesma validação cruzada estratificada de 5 folds, em 140.109 registros de treino.

Modelo	F1 macro (CV)	Acurácia (CV)	Tempo/fold
Regressão Logística	0,8072 ± 0,0010	0,8487	1,0 s
Árvore de Decisão	0,8087 ± 0,0018	0,8556	0,4 s

Modelo	F1 macro (CV)	Acurácia (CV)	Tempo/fold
Random Forest	0,8060 ± 0,0014	0,8542	5,4 s
Gradient Boosting (Hist)	0,8094 ± 0,0013	0,8557	3,0 s
MLP (rede neural)	0,8093 ± 0,0017	0,8555	9,8 s

Resultado central desta comparação: houve empate técnico entre os cinco algoritmos, com F1 macro variando entre 0,8060 e 0,8094 — uma diferença da mesma ordem de grandeza do desvio-padrão entre folds ($\pm 0,001$ a $\pm 0,002$). Diferentemente do relatado na Sprint 1 (Random Forest apontado como opção definitiva por robustez, com Gradient Boosting "marginalmente superior" e não adotado), esta Sprint mostra que **o teto de desempenho é determinado pelo conjunto de features disponíveis, e não pela escolha do algoritmo**. O Gradient Boosting foi selecionado por apresentar o maior F1 macro médio, critério definido antes de qualquer contato com o conjunto de teste.

6.3 Ajuste de hiperparâmetros e modelo final

Uma busca aleatória (RandomizedSearchCV, 12 configurações × 3 folds) foi realizada sobre o algoritmo finalista, avaliando taxa de aprendizado, número de folhas, regularização L2 e tamanho mínimo de folha. A melhor configuração encontrada (`learning_rate=0,05`, `max_leaf_nodes=15`, `min_samples_leaf=20`, `l2_regularization=0,1`, `max_iter=100`) elevou o F1 macro em validação cruzada de apenas 0,8094 para 0,8095 — um ganho de +0,0001, reforçando que o ajuste fino de hiperparâmetros já não tinha muito o que otimizar.

No conjunto de teste, o modelo final entregou **acurácia global de 85,6%** e **F1 macro de 0,809**, superando a melhor referência simples (0,818 / 0,745) em 3,8 pontos percentuais de acurácia e 6,4 pontos de F1 macro — um ganho real, porém modesto, típico de um problema em que a maior parte do sinal já está concentrada em uma ou duas variáveis. A diferença entre F1 macro de treino (0,8104) e de teste (0,8092) foi de apenas 0,0012, descartando overfitting relevante.

Perfil	Precisão	Recall	F1	Suporte
Cliente Esquecido	0,94	1,00	0,97	14.020
Cliente de Abandono	0,84	0,88	0,86	13.851
Cliente Fiel	0,69	0,54	0,61	7.157




Figura 2 — Matriz de confusão normalizada por classe real, no conjunto de teste.

A classe "Cliente Esquecido" repete o excelente desempenho já observado na Sprint 1 (recall próximo de 100%). A leitura muda, porém, para a classe "Cliente Fiel": com F1 de apenas 0,61, ela é a mais

difícil de separar — 2.377 dos 7.157 clientes fiéis do teste (33%) foram confundidos com "Abandono". Isso é esperado: o cadastro do veículo (ano, modelo, prazos) não contém nenhuma informação sobre engajamento comportamental, que é justamente o que distingue um cliente fiel de um que abandonou a rede.

6.4 Análise de sensibilidade: quanto do desempenho vem da idade do veículo?

Para investigar a circularidade descrita na seção 5, o mesmo modelo (mesmos hiperparâmetros) foi retreinado com conjuntos de features cada vez mais restritos, removendo progressivamente as variáveis que dependem da data de referência.




Figura 3 — F1 macro e acurácia no teste, por conjunto de features.

Cenário	Acurácia	F1 macro	ROC-AUC
A. Base ativa (modelo final)	0,856	0,809	0,927
B. Sem tempo_garantia_ate_hoje	0,840	0,801	0,921
C. Sem ano nem tempo de garantia ("Dia Zero")	0,736	0,585	0,819
D. Só o modelo do veículo (ModelName)	0,720	0,538	0,777

O resultado é conclusivo: removendo apenas o tempo de garantia decorrido (cenário B), o F1 macro cai pouco (0,809 → 0,801), porque o ano_modelo ainda carrega a idade do veículo. Removendo também a idade (cenário C, que aproxima o "Dia Zero" real da venda), o F1 macro despenca para 0,585 — ainda acima do acaso, mas muito distante do desempenho reportado como "predição no Dia Zero" na Sprint 1. Esta é a evidência técnica por trás do reenquadramento do projeto como scoring da base ativa (seção 1).

6.5 O modelo agrega valor dentro de cada geração de veículos?

Como a idade do veículo quase define o rótulo — coortes recentes (2024 a 2026) são majoritariamente "Esquecidas" simplesmente por estarem em garantia — a acurácia global pode induzir a uma leitura otimista demais. A comparação relevante é feita dentro de cada coorte de ano-modelo, contra a classe majoritária daquela coorte especificamente.




Figura 4 — Acurácia por coorte de ano-modelo no teste: modelo final × classe majoritária da coorte.

Nas coortes de 2024 a 2026, o ganho do modelo sobre a classe majoritária da coorte é nulo (0,0 pontos percentuais) — quase todos os veículos são "Esquecidos" por estarem em garantia, e prever isso não exige um modelo. O valor real do modelo aparece nas coortes mistas, de 2019 a 2023, com ganhos de +29,3, +3,7, +5,5, +15,0 e +28,1 pontos percentuais de acurácia sobre a classe majoritária de cada coorte, respectivamente — nessas faixas de idade, o modelo de fato diferencia veículos que seguiram caminhos distintos dentro da mesma geração.

7. EXPLICABILIDADE E IMPORTÂNCIA DAS VARIÁVEIS

A Sprint 1 media a relevância das variáveis pela redução média de impureza Gini (MDI) do Random Forest — uma métrica conhecida por favorecer variáveis contínuas de alta cardinalidade, independentemente do seu efeito real no desempenho. Nesta Sprint, a explicabilidade foi recalculada por **importância por permutação**: cada feature é embaralhada, uma de cada vez, no conjunto de teste, e mede-se a queda resultante no F1 macro — uma medida direta do impacto no desempenho, e não apenas da estrutura interna das árvores.




Figura 5 — Importância por permutação: queda no F1 macro ao embaralhar cada feature (5 repetições).

Feature	Queda no F1 macro
tempo_garantia_ate_hoje	0,3206 ± 0,0038
ModelName (modelo do veículo)	0,1766 ± 0,0011
ano_modelo	0,1273 ± 0,0017

Feature	Queda no F1 macro
dias_venda_entrega	0,0006 ± 0,0004
dias_entrega_garantia	≈ 0,0000 ± 0,0002

O resultado confirma, com uma métrica mais robusta, o mesmo achado central da Sprint 1: o tempo decorrido desde o início da garantia é, de longe, a variável mais relevante — sua ausência sozinha derruba o F1 macro em 0,32, mais que o dobro do impacto do modelo do veículo (0,18) e da idade (0,13). Os prazos logísticos de venda e entrega, por outro lado, têm contribuição residual, atuando apenas como refinamento fino da fronteira de decisão. Essa concentração de importância é exatamente o que a análise de sensibilidade da seção 6.4 já havia quantificado em termos de desempenho.

8. IMPLEMENTAÇÃO OPERACIONAL NA REDE DE CONCESSIONÁRIAS

O valor de negócio do ecossistema Ford Vision está em inverter a lógica do pós-venda, de uma cultura reativa para uma abordagem preventiva orientada a dados. Nesta Sprint, essa proposta deixou de ser apenas conceitual: o modelo foi efetivamente empacotado, versionado e exposto como um microserviço (API construída em FastAPI, com testes automatizados), pronto para integração com a API de negócio da solução — responsável por autenticação e perfis de acesso.

8.1 Dois modos de uso

- **Tempo real** (endpoint `/predict`): dado o cadastro de um veículo (modelo, ano, datas de venda, entrega e início de garantia), a API devolve as probabilidades de cada perfil, o perfil mais provável, um score de risco combinado e uma ação de retenção sugerida — útil, por exemplo, na tela do veículo dentro do app da concessionária.
- **Lote** (endpoint `/predict/batch`, e o processo de geração de leads do notebook): pontua toda a base ativa de uma vez, usando predições *out-of-fold* — cada veículo é avaliado por um modelo que não o viu durante o treino — para gerar um ranking de concessionárias por volume de veículos em risco de abandono, alimentando campanhas segmentadas.

Como demonstração, as 395 concessionárias da base foram ranqueadas pelo volume de veículos com perfil de Abandono previsto. A concessionária de maior volume concentra 2.093 veículos nesse perfil (61,5% da sua carteira ativa), enquanto a 10ª colocada tem 24,5% de sua carteira em risco — uma variação relevante que justifica priorização por unidade, em vez de uma campanha genérica para toda a rede.

8.2 Ressalva de enquadramento

Diferentemente da proposta original de disparo no "Dia Zero" da entrega das chaves (Sprint 1), o uso recomendado nesta Sprint é o **scoring periódico da base ativa**: à medida que o tempo de garantia avança, a pontuação do veículo é recalculada, permitindo à concessionária agir antes que o cliente efetivamente migre para uma oficina independente — e não apenas no instante da venda, quando o sinal preditivo disponível é, como demonstrado na seção 6.4, consideravelmente mais fraco.

9. CONCLUSÃO

O projeto Ford Vision, em sua terceira Sprint, evoluiu de uma prova de conceito inicial para uma solução tecnicamente mais rigorosa e honesta sobre suas próprias limitações — o que consideramos um resultado tão relevante quanto os números de desempenho em si. Os principais achados desta etapa são:

- **Diagnóstico do risco latente confirmado:** a segmentação K-Means (K=3, silhouette 0,453) mantém a leitura da Sprint 1 — 79,6% da base ativa (144.350 veículos) está nos perfis "Esquecido" ou "Abandono", validando a relevância do desafio proposto pela Ford.
- **Comparação rigorosa de algoritmos:** cinco famílias de modelos, avaliadas sob o mesmo protocolo, empataram tecnicamente (F1 macro entre 0,806 e 0,809). O Gradient Boosting foi selecionado por critério pré-definido, e o ajuste de hiperparâmetros confirmou que o teto de desempenho está nas features disponíveis, não no algoritmo.
- **Desempenho honesto no teste:** acurácia de 85,6% e F1 macro de 0,809, superando em 3,8 e 6,4 pontos percentuais, respectivamente, a melhor referência simples testada. O ganho é real, mas modesto — e maior nas coortes de veículos com 2 a 6 anos de idade (até +28,1 p.p. sobre a classe majoritária local) do que nas coortes recentes (ganho nulo, pois quase todo veículo novo já é "Esquecido" por estar em garantia).
- **Circularidade identificada e quantificada:** ao contrário da Sprint 1, que declarava conformidade total com a política anti-vazamento sem testá-la, esta Sprint mediu diretamente o quanto do desempenho depende de informações só disponíveis após a venda. Sem elas, o F1 macro cai de 0,809 para 0,585 — motivando o reenquadramento do produto como scoring da base ativa, e não como predição no "Dia Zero".
- **Solução levada a produto:** o modelo foi empacotado, versionado e servido por uma API com testes automatizados, incluindo geração de leads por concessionária a partir de predições out-of-fold — passo ausente na Sprint 1.

Limitações reconhecidas. O rótulo usado no treino é um pseudo-rótulo derivado de uma clusterização, não uma evasão observada por uma fonte independente. A base contém apenas veículos com ao menos uma visita à rede oficial — o que caracteriza um viés de sobrevivência, já que o VIN Share real depende também dos veículos que nunca retornaram. Os pesos usados no score de risco (0 / 0,5 / 1,0 por perfil) são premissas de negócio a validar com a Ford, e não parâmetros aprendidos dos dados.

Trabalhos futuros. Cruzar com a base completa de vendas para medir evasão real e não apenas comportamento entre quem retornou; aprofundar a segmentação com K=4, já identificado como uma leitura de negócio válida na seção 3; enriquecer as features com dados de veículos conectados, região e concessionária; calibrar os pesos do score de risco com a Ford e validar o ganho das ações de retenção com testes A/B controlados.

Em suma, esta entrega consolida uma base metodológica mais sólida que a da Sprint anterior: mantém os achados de negócio validados, corrige e testa hipóteses que antes eram apenas declaradas, e entrega uma prova de conceito que já opera como um serviço real, honesta sobre onde funciona bem — e onde ainda precisa de mais dados.