

FORD VISION

PROJETO DE SEGMENTAÇÃO E CLASSIFICAÇÃO PREDITIVA PARA RETENÇÃO NO PÓS-VENDA

Disciplina: Inteligência Artificial & Machine Learning

Instituição: FIAP — Faculdade de Informática e Administração Paulista

Parceiro Corporativo: Ford Motor Company

Turma: 3ESS — Engenharia de Software

Sprint: 1º Semestre / 2026

Integrantes do Grupo de Desenvolvimento:

Ricardo Di Tilia (RM555155) | Bento Rangel (RM559124) | Eric Yuji (RM554869) | Kauê Pires (RM554403) | Higor
Batista (RM558907)

1. INTRODUÇÃO E CONTEXTUALIZAÇÃO DO PROBLEMA DE NEGÓCIO



A sustentabilidade financeira e a rentabilidade de longo prazo de uma montadora automobilística dependem fortemente da eficiência de sua rede de pós-venda. No cenário da América do Sul, a Ford Motor Company identificou a necessidade crítica de impulsionar o seu indicador de *VIN Share*, que mensura a fatia de veículos ativos da marca que realizam manutenções, reparos e revisões periódicas dentro das concessionárias autorizadas, em detrimento de oficinas mecânicas independentes. A perda do vínculo com o cliente após o término do período de garantia de fábrica representa uma degradação significativa no Customer Lifetime Value (LTV) e reduz a previsibilidade de receita operacional da rede concessionária.

O principal obstáculo para a mitigação desse cenário reside no caráter reativo das abordagens tradicionais de Relacionamento com o Cliente (CRM). Sistemas convencionais operam identificando a evasão apenas após um longo período de inatividade do veículo, momento em que o resgate do consumidor exige custos promocionais proibitivos e possui baixa taxa de conversão.





Para mitigar esse gap operacional, o projeto **Ford Vision** propõe a arquitetura de uma solução fundamentada em Ciência de Dados, dividida em duas grandes fases metodológicas. Primeiramente, aplica-se uma modelagem não supervisionada sobre a base histórica de serviços para o mapeamento e caracterização de perfis comportamentais distintos. Em seguida, implementa-se um pipeline de aprendizado supervisionado baseado em variáveis estáticas disponíveis estritamente no momento do faturamento e entrega do veículo. Isso permite classificar novos consumidores de forma preditiva no "dia zero", viabilizando a ativação de régulas de relacionamento altamente customizadas antes que qualquer comportamento de abandono se concretize.

2. ANÁLISE EXPLORATÓRIA, TRATAMENTO DE DADOS E GOVERNANÇA DO PIPELINE

O volume inicial de dados disponibilizado para o estudo compreendia uma matriz transacional com 602.788 registros de passagens pelas oficinas da rede. Para garantir a integridade estatística das modelagens subsequentes, o ecossistema passou por um rigoroso processo de auditoria e saneamento. Durante a análise exploratória da distribuição das quilometragens reportadas, foram detectados 2.582 registros que apresentavam valores superiores a 1.000.000 km rodados. Uma análise aprofundada confirmou que esses valores consistiam em falhas gritantes de preenchimento e erros de digitação nos sistemas de entrada das oficinas. A manutenção dessas anomalias causaria distorções severas no cálculo dos centroides dos algoritmos de agrupamento, razão pela qual foram sumariamente eliminadas do conjunto de dados.




Superada a fase de limpeza dos outliers físicos, a base transacional sofreu um processo de agregação estrutural tendo como chave primária o Número de Identificação do Veículo (VIN). Essa transformação mudou o nível de granularidade do dataset de "passagens por ordem de serviço" para "clientes únicos", consolidando um volume final consolidado de 175.137 instâncias operacionais. A partir dessa agregação, foram engenheiradas métricas comportamentais robustas para alimentar a segmentação, destacando-se a volumetria total de visitas efetuadas, o intervalo de dias decorridos desde a última interação registrada (recência) e o status temporal de vigência da garantia de fábrica.




3. MODELAGEM NÃO SUPERVISIONADA: SEGMENTAÇÃO ALGORÍTMICA COM K-MEANS

A estruturação dos perfis de pós-venda foi executada por meio do algoritmo de clusterização K-Means. Devido à complexidade computacional inerente ao cálculo da matriz de distâncias pareadas necessária para a validação pelo coeficiente de silhueta, que opera em ordem de magnitude quadrática $O(N^2)$, adotou-se como prática padrão em Data Science a extração de uma amostra estratificada aleatória de 10.000 registros para guiar a otimização dos hiperparâmetros.

A definição do número ideal de agrupamentos (K) envolveu o cruzamento analítico entre a Inércia (Método do Cotovelo) e o *Silhouette Score*. Na avaliação estatística pura, a configuração com K=4 apresentou o coeficiente de silhueta mais elevado, atingindo a marca de 0,467. Contudo, ao inspecionar a composição interna das partições geradas por essa configuração, constatou-se que o algoritmo isolou um cluster espúrio contendo apenas 3 registros altamente atípicos. Cenários dessa natureza configuram um sobreajuste (overfitting) algorítmico, inviabilizando qualquer aplicação prática em grande escala no negócio.




Por conseguinte, a equipe selecionou a configuração técnica com **K=3**, que registrou um *Silhouette Score* sólido de 0,453. Essa estrutura demonstrou alta estabilidade matemática, distribuições volumétricas balanceadas entre as partições e permitiu uma tradução semântica direta para regras de negócio inteligíveis, atendendo integralmente à exigência pedagógica de banir nomenclaturas matemáticas opacas do tipo "Cluster 0" ou "Cluster 1".



4. CARACTERIZAÇÃO DOS PERFIS ESTRATÉGICOS E SENSIBILIDADE COMERCIAL


Os três agrupamentos resultantes foram dissecados e correlacionados com as dores comerciais da Ford, revelando uma base altamente polarizada em que o risco latente de evasão engloba impressionantes 78,7% do volume geral de clientes monitorados.



Abaixo, a tabela detalha o dimensionamento populacional, os padrões operacionais consolidados e as diretrizes recomendadas para as frentes de marketing e fidelização:

Perfil Identificado	Volume / Proporção	Métricas e Comportamento Observado	Plano de Ação e Régua de Relacionamento
Cliente Esquecido	70.829 clientes (40,4%)	Consumidores que possuem cobertura ativa de garantia de fábrica e mantêm contatos recentes com a rede, porém exibem um histórico irregular de revisões obrigatórias. Apresentam elevado potencial de evasão se não estimulados.	Máxima Sensibilidade Comercial. Ativação de alertas automatizados via canais digitais (WhatsApp e push notifications), ênfase nos benefícios de blindagem da garantia contratual e campanhas de agendamento preventivo.
Cliente de Abandono	66.941 clientes (38,2%)	Veículos com ciclos severamente defasados, registrando hiato de comparecimento superior a 36 meses. A garantia contratual encontra-se inteiramente expirada, concentrando o núcleo mais crítico de perda de <i>VIN Share</i> .	Baixa Sensibilidade Inicial. Demanda ofertas comerciais agressivas fora do escopo padrão, tais como vouchers de diagnóstico gratuito de segurança, pacotes fechados de lubrificação com preços subsidiados e campanhas de reativação via CRM.

Perfil Identificado	Volume / Proporção	Métricas e Comportamento Observado	Plano de Ação e Régua de Relacionamento
Cliente Fiel	37.367 clientes (21,3%)	O pilar de sustentação das oficinas. Registram um engajamento histórico de altíssima intensidade, ostentando uma média expressiva de 7,6 passagens ao longo da vida útil do automóvel. Mantêm fidelidade total à rede oficial.	Sensibilidade Baseada em Valor. Inclusão em programas de recompensas com pontuação diferenciada, facilidades exclusivas como serviços de "Leva e Traz", prioridade na agenda das oficinas e táticas de cross-selling de acessórios originais.



5. MODELAGEM SUPERVISIONADA E PROTOCOLO ESTRITO ANTI-DATA LEAKAGE


Com as classes consolidadas pela análise não supervisionada, o projeto avançou para a construção do motor preditivo (Base 2). O edital do desafio estabeleceu um critério eliminatório rígido: a proibição absoluta de vazamento de dados (*data leakage*). O vazamento ocorre quando variáveis que registram eventos cronologicamente posteriores ao momento da predição são incluídas inadvertidamente no treinamento do modelo, gerando métricas artificialmente infladas em ambiente de desenvolvimento que colapsam em produção real.

Para garantir compliance total com essa restrição, todas as features vinculadas ao comportamento histórico nas oficinas (frequência total de serviços, datas de passagem e quilometragens acumuladas pós-entrega) foram eliminadas do conjunto de treino da Base 2. O pipeline preditivo foi restrito a uma matriz de 8 preditores estáticos conhecidos exclusivamente no instante em que o veículo sai do pátio faturado:

- **Ano do Modelo** (``ano_modelo``): Indicador geracional do veículo.
- **Dias de Venda até Entrega** (``dias_venda_entrega``): Intervalo logístico do faturamento físico.
- **Canal de Entrada Codificado** (``is_agenda_encoded``): Origem da jornada do lead de vendas.
- **Tempo de Garantia até a Data Atual** (``tempo_garantia_ate_hoje``): Mapeamento do ciclo de cobertura legal.
- **Idade Proxy do Automóvel** (``idade_veiculo_proxy``): Depreciação temporal estimada.

6. AVALIAÇÃO DE DESEMPENHO E CRITÉRIOS TÉCNICOS DE SELEÇÃO DE ARQUITETURAS


O processo de seleção de algoritmos envolveu a validação cruzada (Cross-Validation) com partição em múltiplos folds sobre diferentes famílias de modelos. Avaliou-se o desempenho comparativo entre a Regressão Logística Multinomial, Random Forest e classificadores baseados em Gradient Boosting (como XGBoost).



Embora os classificadores baseados em Gradient Boosting tenham exibido um F1-Score marginalmente superior (0,84) nos testes iniciais, o algoritmo **Random Forest** consolidou-se como a escolha técnica definitiva. A arquitetura de florestas aleatórias alcançou um F1-Score médio estável de 0,8023 sob validação cruzada e demonstrou uma superioridade crítica em termos de engenharia de software: menor sensibilidade a hiperparâmetros, imunidade a desvios severos de overfitting e, crucialmente, um custo computacional de inferência em tempo real significativamente inferior. Essa característica é vital para suportar o volume de requisições concorrentes geradas por centenas de concessionárias conectadas simultaneamente no continente.

No conjunto de testes independente, o classificador Random Forest final entregou uma **acurácia global de 83,16%**. A análise detalhada da matriz de confusão e do relatório de classificação expõe a eficácia do modelo no mapeamento das classes de risco:


- **Classe 'Cliente Esquecido'**: Obteve desempenho excepcional com **95% de Precisão** e assombrosos **98% de Sensibilidade (Recall)**. Isso significa que o modelo captura virtualmente todos os clientes desse perfil, permitindo agir sobre o maior vetor de conversão de curto prazo.
- **Classe 'Cliente de Abandono'**: Registrou um **Recall robusto de 86%**, garantindo que a Ford consiga interceptar antecipadamente a grande maioria dos consumidores propensos a abandonar a rede de serviços oficiais.



7. ENGENHARIA DE RECURSOS E IMPORTÂNCIA DAS VARIÁVEIS (FEATURE IMPORTANCE)

A fim de conferir explicabilidade ao modelo caixa-preta do Random Forest, a relevância de cada recurso foi calculada utilizando o método de decréscimo médio de impureza Gini (MDI). A extração revelou uma assimetria acentuada na capacidade discriminante dos preditores.

A variável isolada de maior impacto preditivo foi o **tempo de garantia restante calculado até a data atual** (`tempo_garantia_ate_hoje`), concentrando de forma soberana **42%** da importância relativa do modelo. Esse comportamento matemático é amparado pela lógica de negócios: o encerramento do vínculo de garantia de fábrica atua como o principal gatilho psicológico e econômico que leva o consumidor a romper o relacionamento com a concessionária e migrar para o mercado independente.



O segundo fator de maior relevância foi a idade proxy estruturada do modelo do veículo, evidenciando que o ciclo de obsolescência natural do bem dita de forma estatisticamente significativa a propensão à evasão. Fatores logísticos de pátio, como o intervalo de dias decorridos entre a venda contratual e o faturamento físico efetivo (`dias_venda_entrega`), atuaram como variáveis secundárias de refinamento de fronteiras de decisão no algoritmo.

8. IMPLEMENTAÇÃO OPERACIONAL NA REDE DE CONCESSIONÁRIAS: A SOLUÇÃO "FORD VISION"

O valor de negócio gerado pelo ecossistema **Ford Vision** reside em sua capacidade de inverter a lógica operacional do pós-venda da Ford, transitando de uma cultura puramente reativa e corretiva para um paradigma integralmente preventivo e centrado em dados.

O fluxo de aplicação no cotidiano da rede de concessionárias é estruturado em quatro etapas operacionais contínuas:

1. **Geração do Input Preditivo:** No exato instante em que o processo de venda de um automóvel zero-quilômetro é finalizado e os dados de faturamento são consolidados no sistema central da concessionária, os parâmetros estáticos do cliente e do veículo são capturados automaticamente.
2. **Inferência em Tempo Real:** Os dados coletados são enviados como um payload via API para o microserviço que hospeda o modelo Random Forest. Em milissegundos, o modelo computa as probabilidades e retorna a classificação probabilística do comprador em um dos três perfis validados (Fiel, Esquecido ou com Propensão ao Abandono).
3. **Disparo da Régua no Dia Zero:** Se o sistema classificar o novo comprador com alto risco de "Abandono", o consultor de pós-venda recebe um alerta em seu terminal de CRM no momento da entrega física das chaves do veículo. Isso possibilita que a concessionária realize uma blindagem comercial imediata, oferecendo a contratação de planos de manutenção preventiva pré-pagos ou concedendo benefícios exclusivos para a realização da primeira revisão de 10.000 km.
4. **Sustentabilidade Financeira:** Ao antecipar as necessidades e mitigar os riscos de evasão de forma proativa sobre os 78,7% da base sob ameaça, a Ford reduz drasticamente o custo de aquisição de clientes inativos, consolida a fidelidade à marca, maximiza a ocupação das oficinas autorizadas e atinge com precisão o objetivo estratégico de alavancar o indicador de *VIN Share* no mercado sul-americano.

9. CONCLUSÃO

O projeto Ford Vision, desenvolvido nesta primeira Sprint do desafio, demonstrou com sucesso a viabilidade acadêmica e o potencial prático de aplicar Inteligência Artificial e Machine Learning para propor soluções no ecossistema de pós-venda automóvel. A jornada de desenvolvimento validou a hipótese inicial do grupo de que abordagens preditivas baseadas em dados podem estruturar melhores estratégias de retenção, superando a lógica reativa dos CRMs tradicionais.

A partir do saneamento da base histórica e do treino do pipeline preditivo proposto, consolidam-se os seguintes achados e conclusões técnicas desta etapa de pesquisa:

- **Diagnóstico do Risco Latente:** A etapa de modelagem não supervisionada (K-Means) cumpriu com a diretriz de traduzir dados em perfis de negócio claros. O agrupamento revelou uma realidade crítica na base estudada: 78,7% dos clientes analisados encontram-se nos perfis "Esquecido" ou de "Abandono". Esse dado quantifica academicamente a relevância do desafio proposto pela Ford, evidenciando que o risco de evasão para oficinas independentes é um fator sistêmico que demanda ações antecipadas.
- **Validação Científica do Gatilho de Evasão:** Através da análise de explicabilidade algorítmica (Feature Importance via redução de impureza Gini), o modelo demonstrou matematicamente que a variável tempo de garantia restante é o principal preditor, concentrando 42% de importância na árvore de decisão. Essa descoberta valida cientificamente a lógica de negócios: o fim iminente da cobertura legal é o principal gatilho para o afastamento do cliente, delimitando exatamente onde as futuras réguas de relacionamento devem atuar.
- **Eficácia do Modelo nos Testes:** O classificador supervisionado Random Forest entregou uma acurácia global de 83,16% nos dados de teste. O maior trunfo do modelo proposto nesta Sprint reside na sua sensibilidade direcionada, alcançando impressionantes 98% de Sensibilidade (Recall) na identificação do "Cliente Esquecido". Por ser o segmento com maior potencial de reversão, a alta taxa de acerto do algoritmo prova que a solução é eficaz em mitigar falsos negativos onde há maior oportunidade de conversão.
- **Compliance contra Data Leakage:** O grupo obteve sucesso na aplicação das regras de governança exigidas no edital. Ao isolar estritamente 8 variáveis conhecidas unicamente no momento do faturamento (como o ano do modelo e o tempo logístico), provou-se que é tecnicamente viável realizar uma classificação confiável e preditiva no "Dia Zero", sem a dependência de dados de comportamento futuro.

Em suma, esta entrega inicial estabelece uma base metodológica sólida para o desafio proposto pela Ford. Embora se trate de um protótipo desenvolvido em ambiente acadêmico nesta primeira Sprint, o ecossistema Ford Vision atingiu com rigor todos os requisitos solicitados, entregando uma prova de conceito madura que ilustra como a inteligência preditiva pode futuramente apoiar o crescimento sustentável do indicador de VIN Share nas concessionárias.